Universidade Federal de Minas Gerais
Instituto de Ciências Exatas
Departamento de Ciência da Computação

Introdução à Inteligência Artificial
Professor: Luiz Chaimowicz
Monitor: Tiago Negrisoli

Trabalho Prático II: Aprendizado por Reforço

Valor: 15 pontos
Data de entrega: 12 de Dezembro de 2022

1 Definição do Problema

Iremos revisitar o cenário do Trabalho Prático I. Dessa vez, o objetivo será praticar conceitos e algoritmos de aprendizado por reforço. Além disso, proporcionará uma forma de entender como funções de recompensa e o ambiente afeta a política gerada pelo agente. Relembrando o problema, será proposto a resolução do Path-Finding. Este é o problema de encontrar um caminho entre dois pontos. Sua aplicação é essencial para diversas áreas. Em jogos, os métodos são usados para guiar a movimentação de NPCs. O mundo do jogo (podendo ser 2D ou 3D) é discretizado em áreas geométricas. A figura 1 mostra um exemplo desse processo. Com esse processo, o tamanho do espaço de estados é reduzido. As possíveis ações do agente são caminhar entre essas áreas executando um movimento entre quatro direções (cima, baixo, direita e esquerda). Quando uma solução é encontrada, o agente apenas executa as ações até alcançar o alvo. Uma questão é que, muitas das vezes, alguns caminhos são preferíveis a outros. Um exemplo é entre escolher o caminho pegando fogo mas que é direto ao objetivo ou decidir contorná-lo e gastando mais passos. Para esse trabalho, iremos lidar com esse problema atribuindo diferentes recompensas baseada em qual terreno (estado) que o agente move. Com isso, você deve implementar o método **Q-Learning**. O seu programa receberá uma representação discretizada do mapa, um estado inicial e um número de passos que o agente deve ser treinado. A saída será a política gerada após o número de passos descrito.

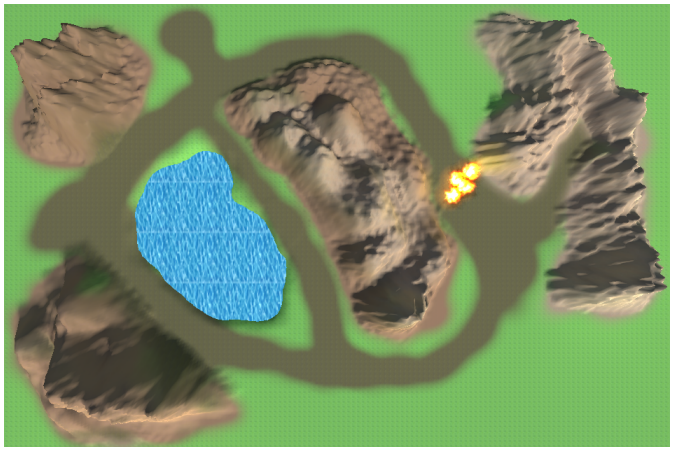

(a) Mundo 3D do jogo

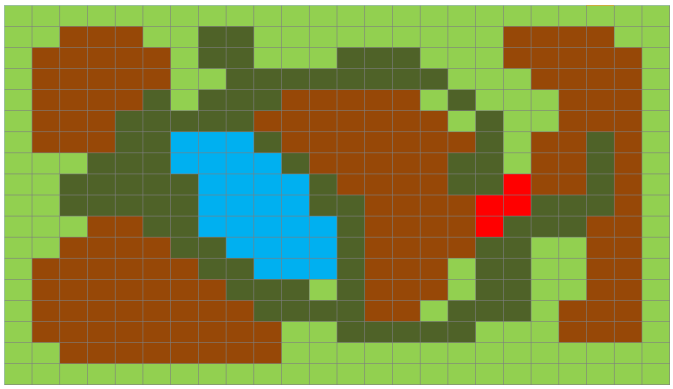

(b) O mapa discretizado

Figura 1: Figura exemplificando o processo de discretização de um mapa. Na figura 1a, é uma representação do mundo 3D com diferentes tipos de terreno. A figura 1b mostra uma versão discretizada, com cores para marcar os diferentes tipos de terrenos.

2 Mapa

O mapa que seu programa receberá será a versão discretizada de um mundo. Essa é modelada por uma matriz bidimensional. Cada posição dessa representa uma área do mapa original do jogo e terá um símbolo que identifica o tipo de terreno. Os símbolos e suas respectivas recompensas estão descritos na tabela 1 a seguir.

Terreno	Símbolo	Recompensa
Grama	.	-0.1
Grama Alta	;	-0.3
Água	+	-1.0
Fogo	x	-10.0
Objetivo	O	10.0
Parede	@	$-\infty$

Tabela 1: Símbolos e recompensas associados a cada terreno

Alguns detalhes para essa nova modelagem. **Quando o agente se encontrar em um estado representado por fogo ou objetivo, o episódio acaba e ele receberá a recompensa apresentada na tabela**.

Além disso, um terreno de parede representa novamente um terreno intransponível. Dessa vez, a ação em direção a esse terreno é **válida**, porém o agente se **manterá no estado em que se encontra**.

As coordenadas assumidas nesse trabalho tem como (0, 0) no canto superior esquerdo do mapa. Um ponto (x, y) representa a altura y e o comprimento x daquele ponto.

3 Ações

O agente pode movimentar em quatro direções (cima, baixo, direita e esquerda). Os movimentos para fora dos limites do mapa ou para terrenos intransponíveis são válidos mas o estado resultante se manterá o mesmo.

4 Métodos

Para o trabalho, você deve implementar o método Q-Learning padrão. Para a taxa de aprendizado, deve-se utilizar o valor $\alpha = 0.1$ e para a taxa de desconto $\gamma = 0.9$. A sua implementação deve fazer uso de um **método de exploração**. Para o trabalho, implemente o ϵ-greedy com o valor de $\epsilon = 0.1$.

Além disso, outras duas versões modificadas devem ser realizadas para fins de comparação de políticas. Essas serão discutidas a seguir.

4.1 Recompensas Positivas

Essa versão apenas modifica a recompensa atribuída para os terrenos. A nova função de recompensa é dada pela tabela 2 a seguir.

Terreno	Símbolo	Recompensa
Grama	.	3.0
Grama Alta	;	1.5
Água	+	1.0
Fogo	x	0.0
Objetivo	O	10.0
Parede	@	-∞

Tabela 2: Símbolos e recompensas associados a cada terreno na versão modificada

4.2 Ambiente Estocástico

Nesta versão, ao escolher e executar uma ação, existe uma chance de 20% de uma ação perpendicular à escolhida ser executada pelo ambiente, sendo 10% para a perpendicular direita e 10% para a esquerda. Assim, a ação escolhida será realizada sem alteração pelo ambiente com 80% de chance.

5 Entrada do programa

O seu programa receberá como argumento uma string que representa o nome do arquivo texto onde o mapa e suas informações serão descritas. Além disso, uma outra string que identifica qual modificação que deve ser utilizado. Por fim, 3 inteiros que representam as coordenadas (x_i, y_i) do estado inicial e n o número de passos que o agente deve ser treinado. Um exemplo de um programa compilado em C/C++ nomeado como *qlearning*, o seguinte comando deve ser usado para rodá-lo.

./qlearning [caminho_para_arquivo_mapa] [identificador_modificacao] x_i y_i n

Em que [identificador_metodo] pode ser *standard*, *positive*, *stochastic* representando: **Q-Learning padrão sem modificações**, **Q-Learning com recompensas apenas positivas**, **Q-Learning com ambiente estocástico** respectivamente. [caminho_para_arquivo_mapa] será a string com o caminho para o arquivo texto.

O arquivo texto apresentará todas as informações referentes ao mapa. A primeira linha do arquivo possui dois inteiros W e H, representando o número de colunas e linhas da matriz respectivamente. Em seguida, as próximas H linhas terão W caracteres representando o tipo de terreno naquela posição sem espaço entre os caracteres. Um exemplo de entrada é descrito a seguir.

```
5 4
+ + + . O
. @ @ . x
. @ @ . .
. ; ; ; .
```

6 Saída do Programa

Seu programa deve computar os valores Q de cada estado do mapa ao longo do treino partindo do estado inicial dado na entrada. Ao final dos n passos, deve-se imprimir na tela o mapa, e para cada posição transponível, um indicador mostrando qual a melhor ação a ser tomada naquele estado. Esses indicadores devem sem >, <, ^ e v para indicar as ações direita, esquerda, cima e baixo respectivamente. Além disso, para estados terminais (como fogo e objetivo) e intransponíveis, o símbolo de seu terreno deve ser impresso. **Não deve** ter espaços em branco nem nenhum outro caractere entre os símbolos. Seu programa deve imprimir **apenas** o descrito.

Um exemplo de política gerada após 100.000 passos com o estado inicial (0,3) é dada a seguir.

```
v > > > O
v @ @ ^ x
v @ @ ^ <
> > > ^ ^
```

7 Entrega

Você deverá entregar um arquivo **ZIP** no Moodle da disciplina. O arquivo **ZIP** deve conter o código-fonte da sua implementação **(C, C++ ou python)**. Além disso, deve contem uma documentação em formato **PDF**. Essa deve descrever de forma sucinta as decisões de implementação e análises. Mais especificamente, deve-se incluir:

- Apresentação das estruturas usadas e da modelagem dos componentes (estado, agente, ambiente, etc);
- Breve descrição do método utilizado e das modificações.
- Análise comparando as políticas geradas pelo método original e suas modificações. Qual o efeito da mudança? A política se alterou? Porque?

Por fim, deve-se ter um **README** descrevendo como rodar (e compilar caso a linguagem necessite) o seu programa. Assim como uma lista de bibliotecas utilizadas.

8 Considerações Finais

- Sinta-se livre para discutir o trabalho com seus colegas. Entretanto, o compatilhamento de códigos ou texto é plágio e será devidamente punido. Seu trabalho deve ser de sua autoria.
- Use o fórum de discussão *Dúvidas/Discussão* do Moodle em caso de dúvidas. Caso prefira, pode enviar um email para o monitor da disciplina.
- Comece o trabalho o mais cedo possível!
- **Bom trabalho!**